


# Deep Learning en Imágenes con GANs y Modelos de Difusión - Parte II

Prof. Peter Montalvo

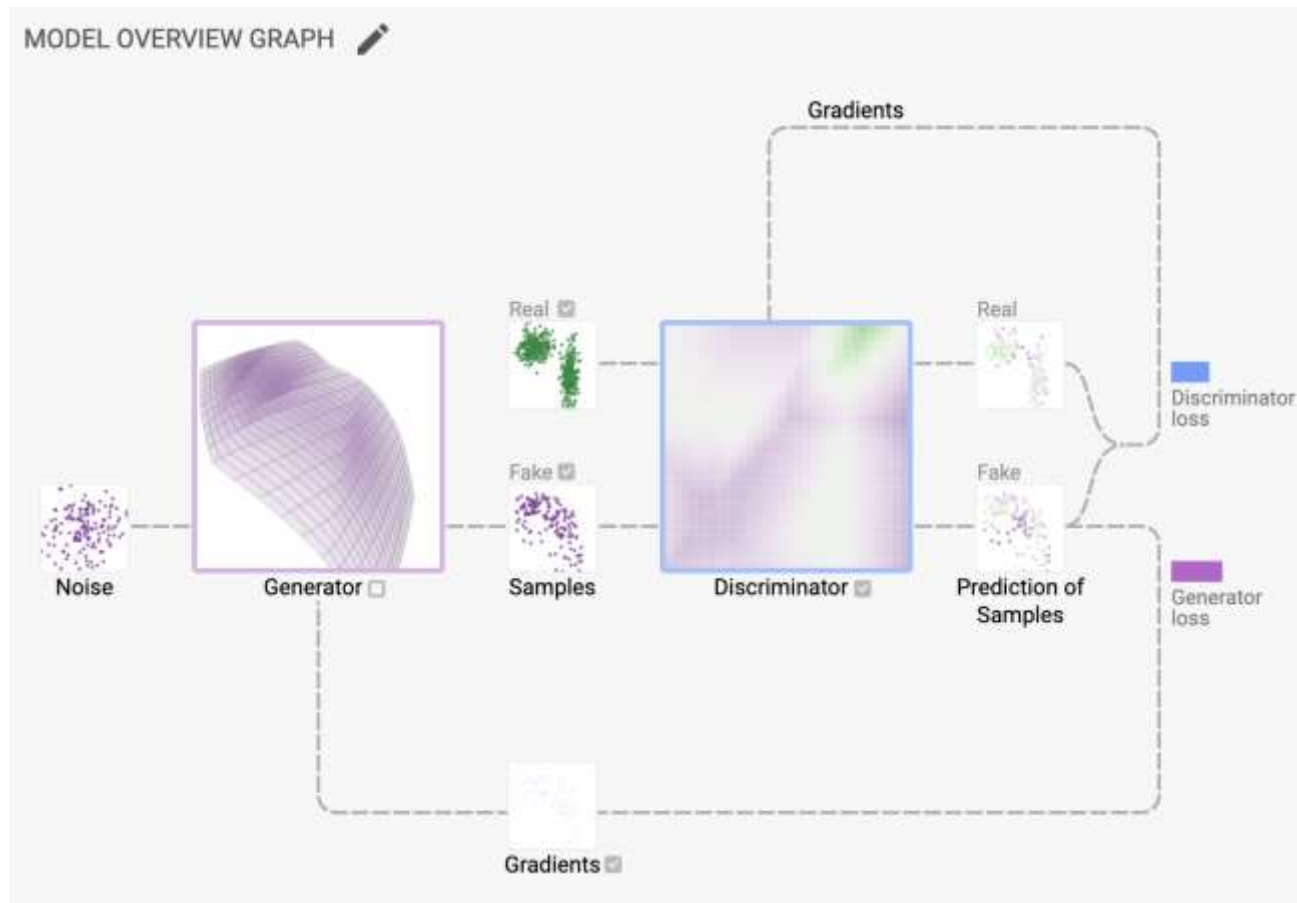
# Agenda

- Introducción
- GANs
- Función de Pérdida
- Aplicaciones
- Wasserstein GAN

# GAN - Generative Adversarial Nets




# Introducción



# Introducción

## LAYERED DISTRIBUTIONS



Each dot is a 2D data sample: **real samples**; **fake samples**.


Background colors of grid cells represent **discriminator's** classifications.  
Samples in **green regions** are likely to be real; those in **purple regions** likely fake.

**Manifold** represents **generator's** transformation results from noise space.  
Opacity encodes density: darker purple means more samples in smaller area.


Pink lines from fake samples represent **gradients** for generator.

✓ This sample needs to move upper right to decrease generator's loss.


## METRICS




# Función de pérdida




(a)



(b)







(c)







(d)

# Función de pérdida



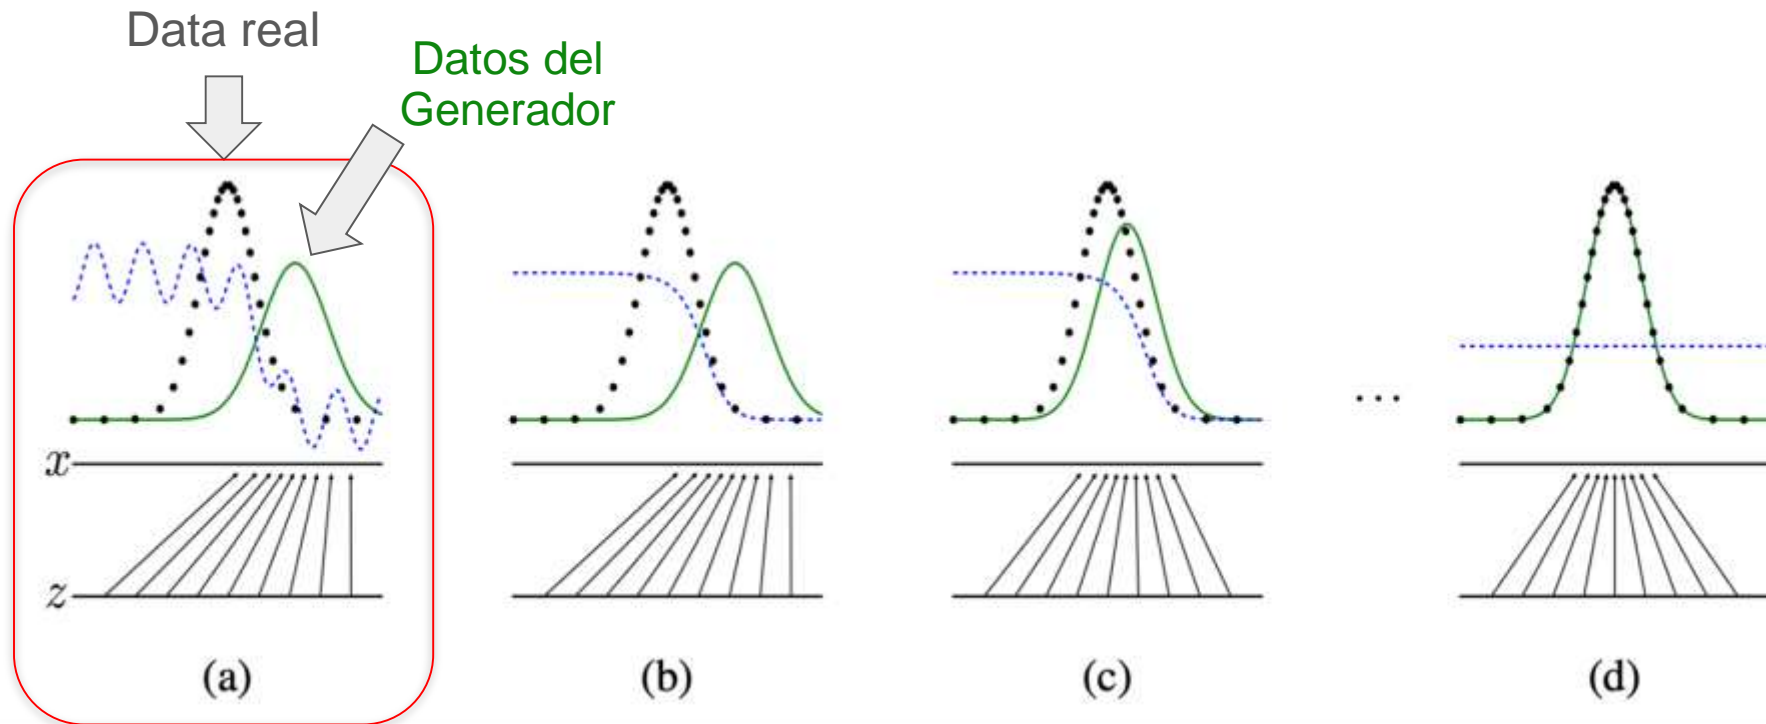
# Función de pérdida

Data real

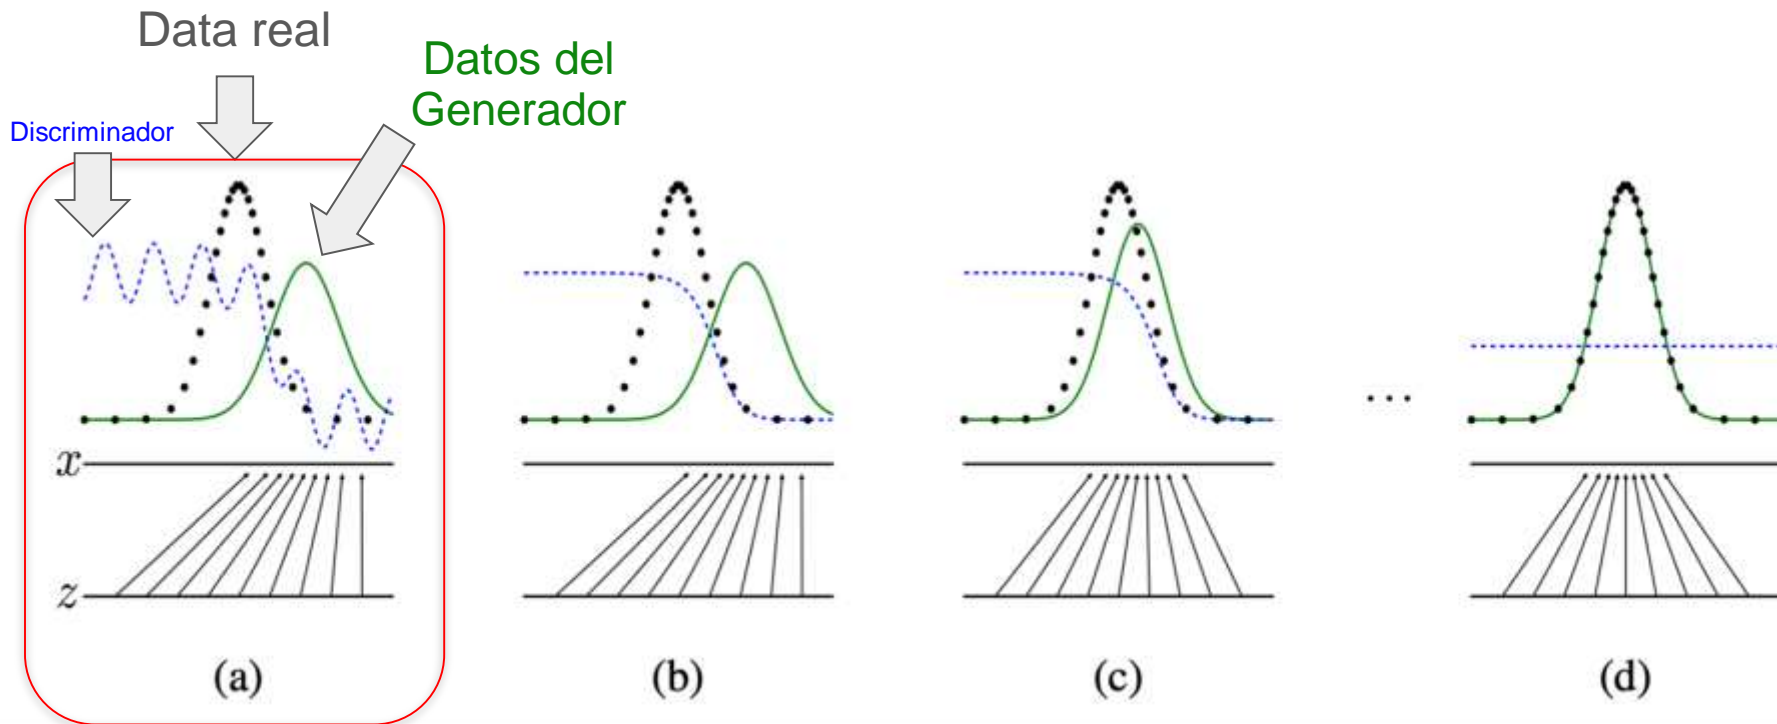





# Función de pérdida




# Función de pérdida




# Función de pérdida




(a)



(b)



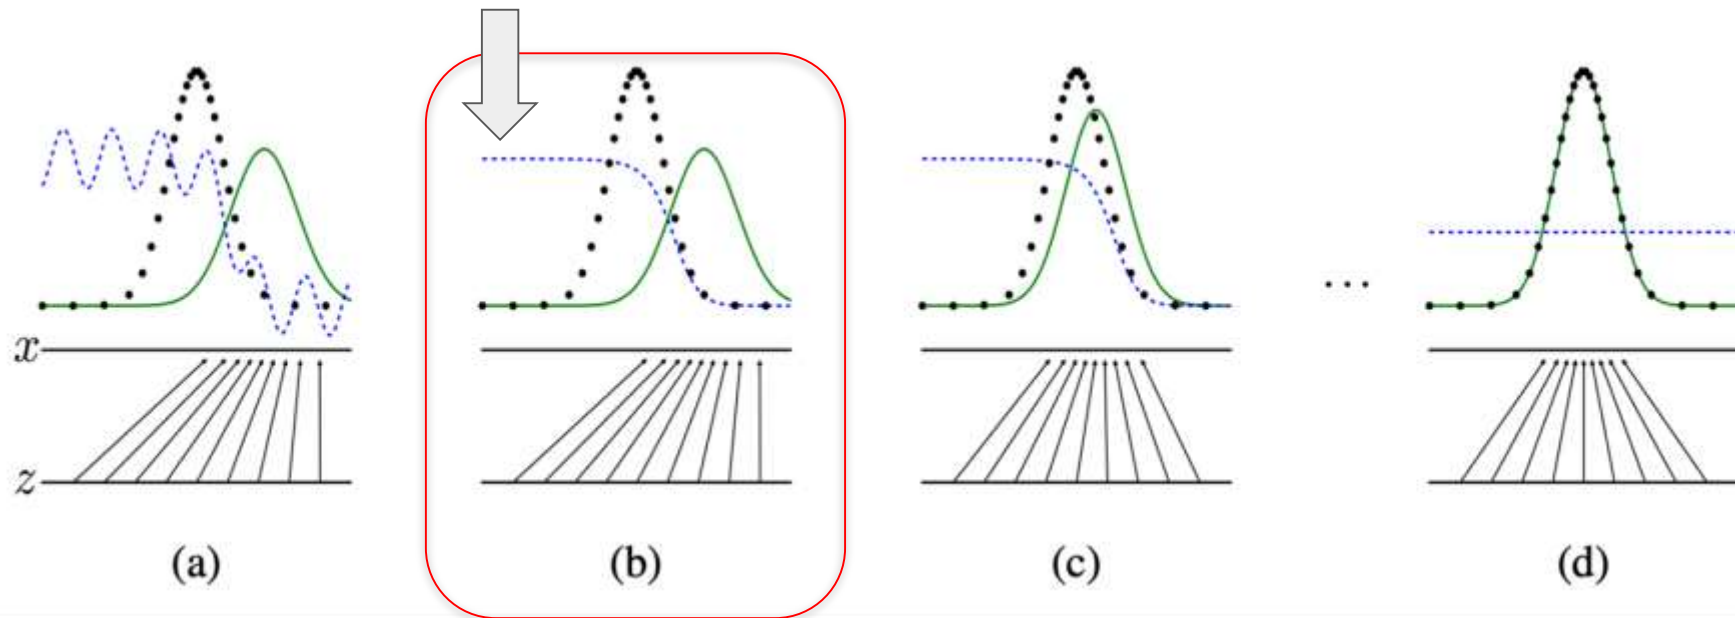
(c)



(d)

# Función de pérdida


Discriminador da  
1 si la data es real




# Función de pérdida

Discriminador da  
**1** si la data es real


Discriminador da **0**  
si la data es falsa



(a)




(b)




(c)

...




(d)


# Función de pérdida




(a)



(b)




(c)




(d)

# Función de pérdida



# Función de pérdida


La distribución de datos falsos se comienza a acercar a la distribución de datos original






# Función de pérdida

La distribución de datos falsos se comienza a acercar a la distribución de datos original




# Función de pérdida

El discriminador comienza a clasificar como 1 a la distribución de data falsa.




# Función de pérdida


El discriminador comienza a clasificar como 1 a la distribución de data falsa.




# Función de pérdida




(a)



(b)

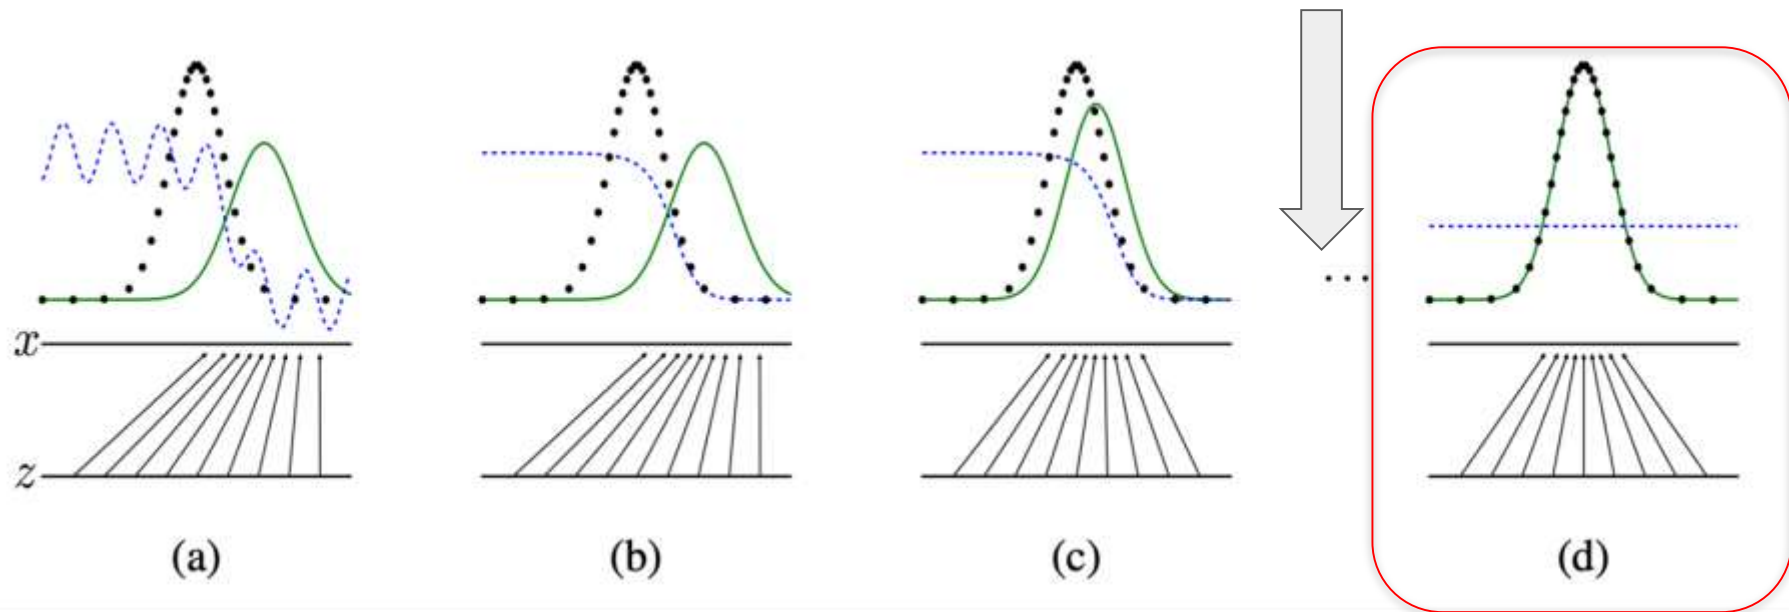


(c)




(d)

# Función de pérdida




# Función de pérdida


Finalmente, luego de algunas iteraciones...




(a)




(b)



(c)



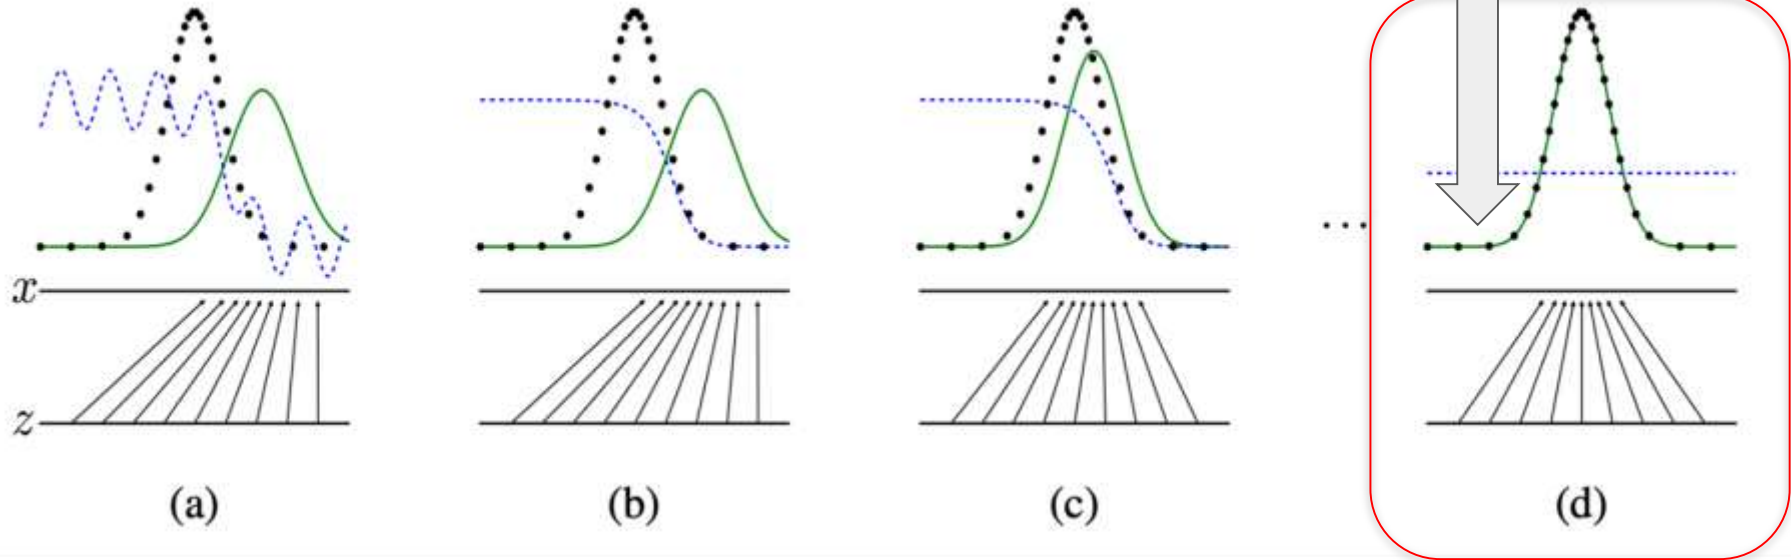
...



(d)

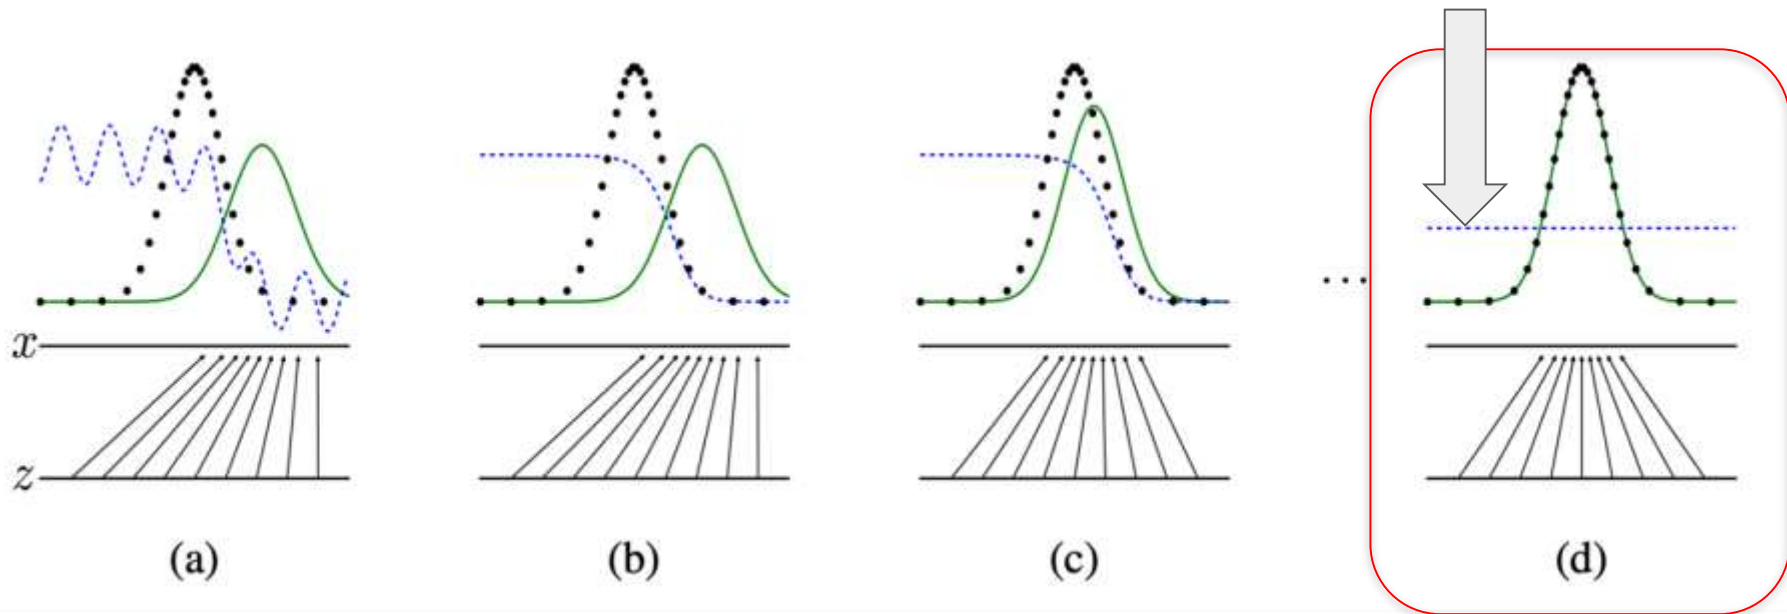
# Función de pérdida

El Generador converge generando data similar a la distribución de data real.



# Función de pérdida


El discriminador converge en 0.5






# Función de pérdida


El generador converge en 0.5 (No puede diferenciar entre real y falso)




(a)



(b)

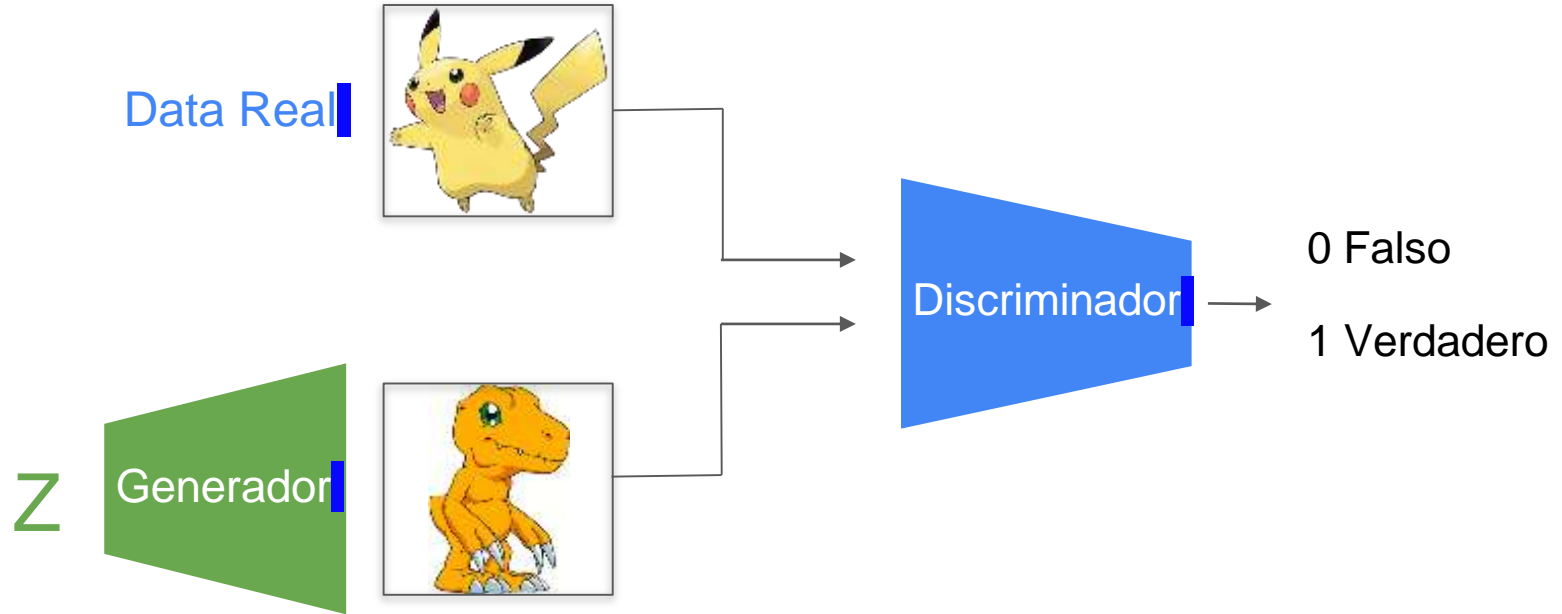


(c)

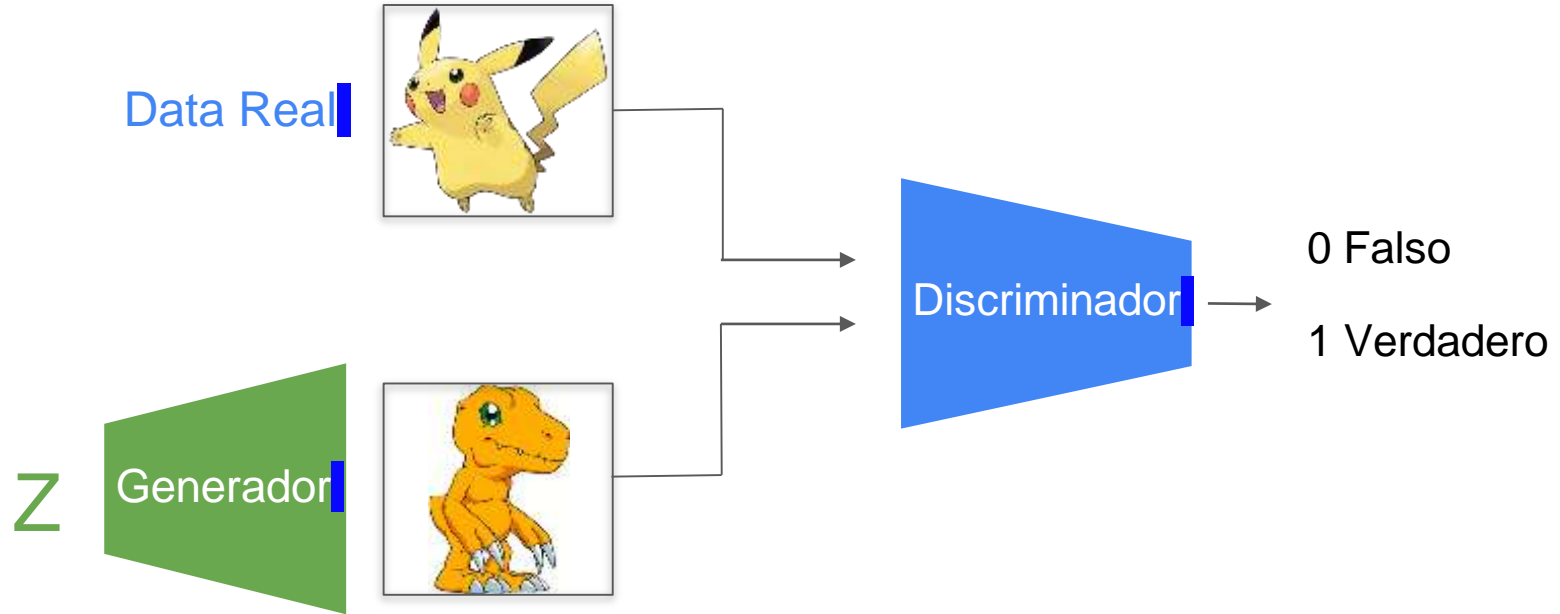


(d)

# Función de pérdida

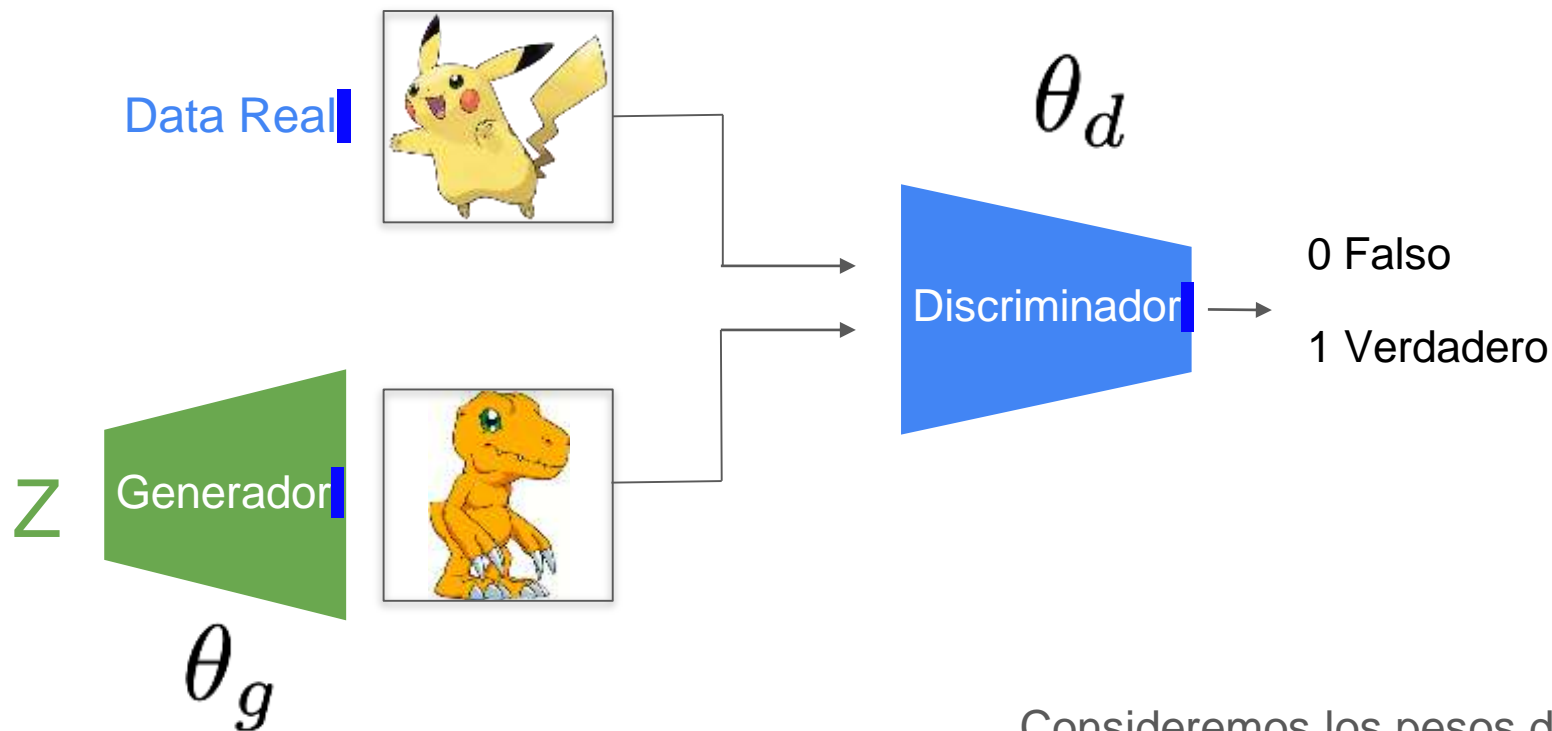


# Función de pérdida



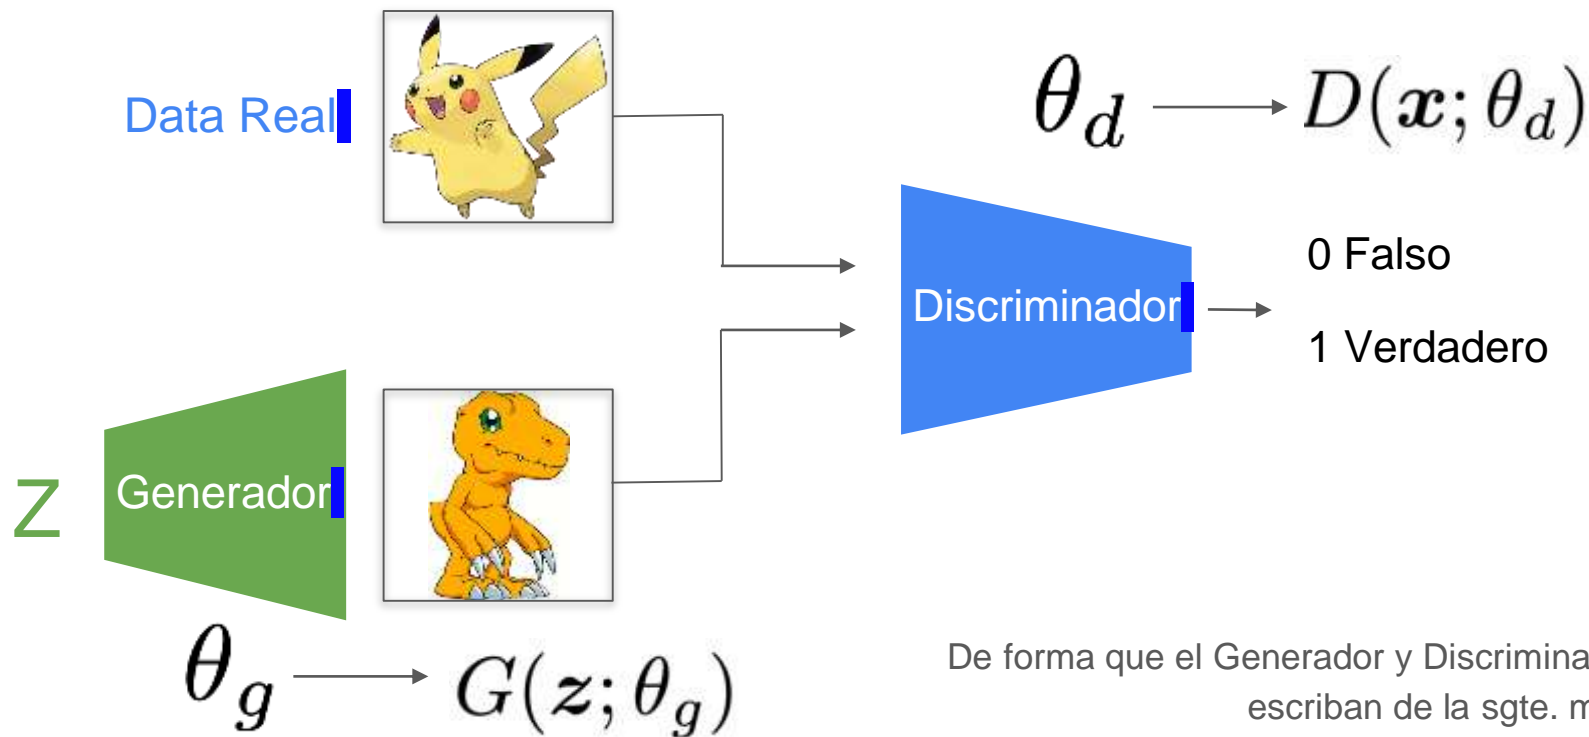
Consideremos los pesos de cada red de la siguiente forma...

# Función de pérdida

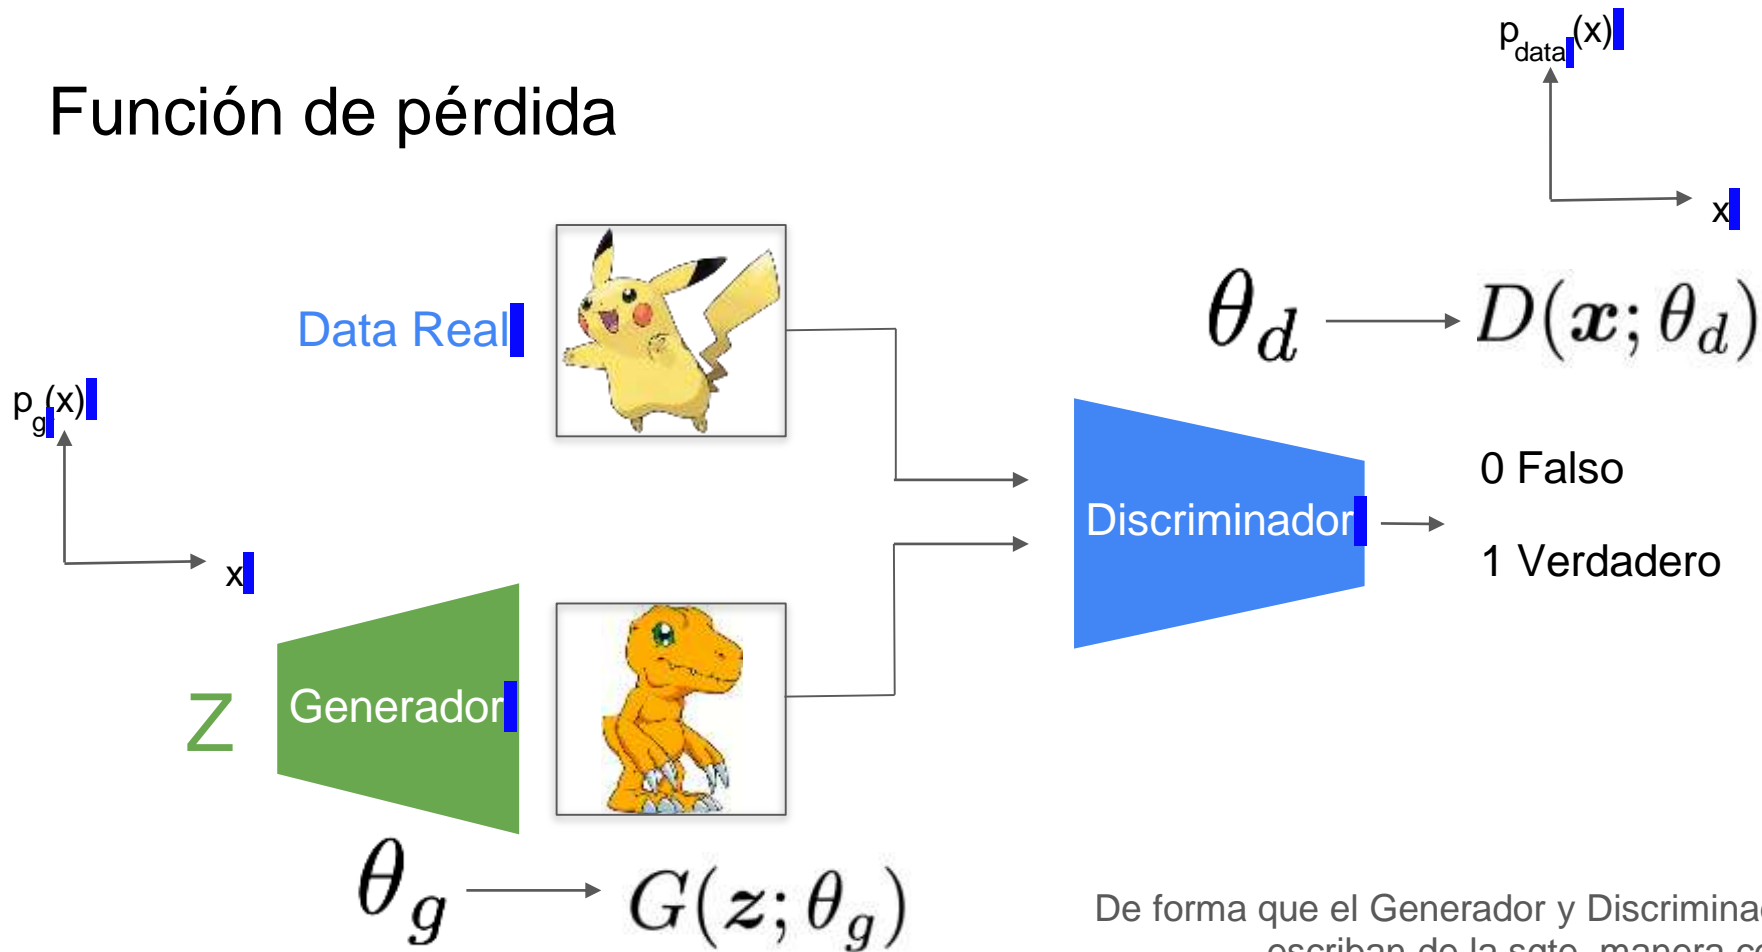


Consideremos los pesos de cada red de la siguiente forma...

# Función de pérdida



# Función de pérdida



De forma que el Generador y Discriminador se escriban de la sgte. manera con sus distribuciones

# Función de pérdida

Función de valor



$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))].$$

De manera que G y D juegan un  
MinMax de 2 jugadores

## Función de pérdida

$$-\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$



Función de BCE

Esto es similar a la función de  
Binary Cross Entropy



## Función de pérdida

$$-\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$



Función de BCE

cuando  $y=1$

$$\hat{y} = D(x) \Rightarrow \mathcal{L} = \ln[D(x)]$$

cuando  $y=0$

$$\hat{y} = D(G(z)) \Rightarrow \mathcal{L} = \ln[1 - D(G(z))]$$

Asimismo, cuando analizamos los valores de  $y=1$  o  $y=0$ , vemos que...

## Función de pérdida

$$\mathcal{L} = \ln[D(x)] + \ln[1 - D(G(z))]$$

De forma que la función de valor  
queda de la sgte. forma

## Función de pérdida

$$\mathcal{L} = \ln[D(x)] + \ln[1 - D(G(z))]$$

Pero esto es para una única muestra.  
Se debe considerar la Esperanza

## Función de pérdida

$$E(x) = \sum x p(x) \leadsto (1+2+3+4+5+6)$$



La Esperanza...

## Función de pérdida

$$E(x) = \sum x p(x) \leadsto \frac{1}{6} (1+2+3+4+5+6)$$



La Esperanza...

## Función de pérdida

$$E(x) = \sum x p(x) \leadsto 3.5$$



La Esperanza...

## Función de pérdida

$$\sum p_{data}(x) \ln[D(x)] + \sum p_z(z) \ln[1 - D(G(z))]$$

Aplicando la Esperanza a nuestra  
función de valor

## Función de pérdida

$$\int p_{\text{data}}(x) \ln[D(x)] dx + \int p_z(z) \ln[1 - D(G(z))] dz$$

Aplicando la Esperanza a nuestra  
función de valor



## Función de pérdida

$$V(G, D) = E_{x \sim p_{\text{data}}} [\ln(D(x))] + E_{z \sim p_z} [\ln(1 - D(G(z)))]$$


Aplicando la Esperanza a nuestra  
función de valor

# Función de pérdida

MINIMIZAR  
 $D$


$$\frac{\partial}{\partial \theta_d} \frac{1}{m} [\ln [1 - D(G(z))]]$$

MAXIMIZAR  
 $G$


$$\frac{\partial}{\partial \theta_g} \frac{1}{m} [\ln [1 - D(G(z))]]$$

cant. de  
muestras

El algoritmo de entrenamiento quedaría de la siguiente forma

# Función de pérdida

---

**Algorithm 1** Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator,  $k$ , is a hyperparameter. We used  $k = 1$ , the least expensive option, in our experiments.

---

**for** number of training iterations **do**

**for**  $k$  steps **do**

- Sample minibatch of  $m$  noise samples  $\{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$  from noise prior  $p_g(\mathbf{z})$ .
- Sample minibatch of  $m$  examples  $\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}\}$  from data generating distribution  $p_{\text{data}}(\mathbf{x})$ .
- Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[ \log D(\mathbf{x}^{(i)}) + \log \left( 1 - D(G(\mathbf{z}^{(i)})) \right) \right].$$

**end for**

- Sample minibatch of  $m$  noise samples  $\{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$  from noise prior  $p_g(\mathbf{z})$ .
- Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log \left( 1 - D(G(\mathbf{z}^{(i)})) \right).$$

**end for**

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

---

El algoritmo de entrenamiento quedaría de la siguiente forma

# Aplicaciones

Crear personajes de anime

<https://arxiv.org/pdf/1708.05509.pdf>



Figure 7: Generated samples

# Aplicaciones

Crear personajes de anime

<https://arxiv.org/pdf/1708.05509.pdf>




Figure 3: Generator Architecture




Figure 4: Discriminator Architecture




Figure 7: Generated samples

# Aplicaciones

Personas posando

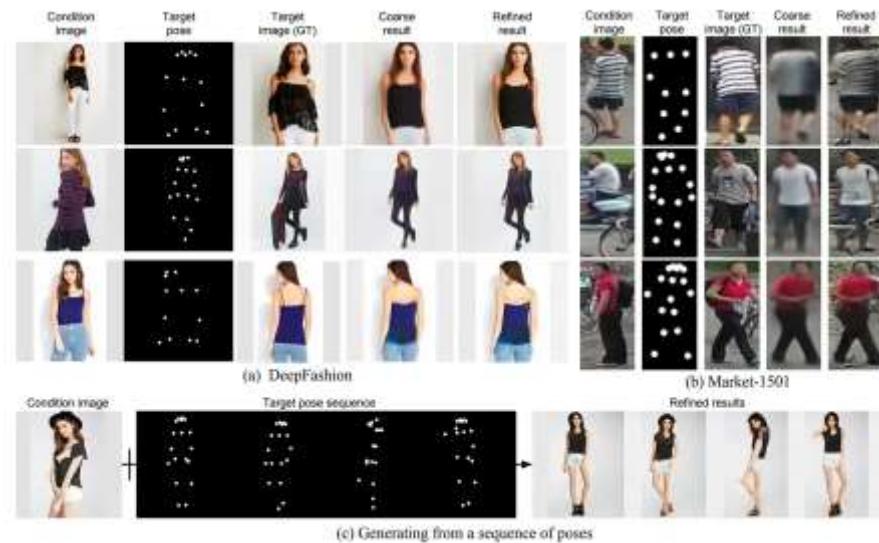

<https://arxiv.org/pdf/1705.09368.pdf>



# Aplicaciones

Personas posando

<https://arxiv.org/pdf/1705.09368.pdf>



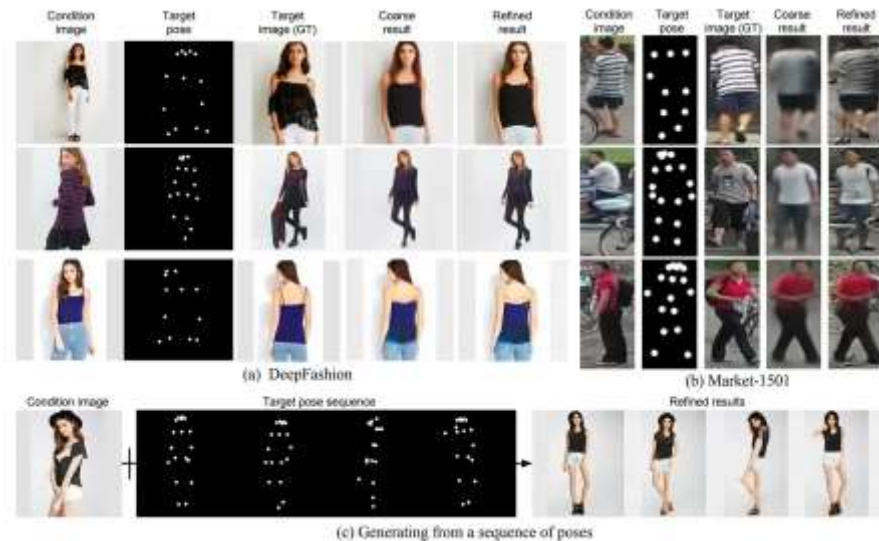




# Aplicaciones

Personas posando

<https://arxiv.org/pdf/1705.09368.pdf>





# Aplicaciones

CycleGAN

<https://github.com/junyanz/CycleGAN>



Photograph



Monet



Van Gogh



Cezanne



Ukiyo-e

# Aplicaciones

CycleGAN

<https://github.com/junyanz/CycleGAN>



Photograph



Monet



Van Gogh



Cezanne



Ukiyo-e

# Aplicaciones

StarGAN

<https://arxiv.org/pdf/1711.09020.pdf>

StarGAN es una traducción de imagen a imagen de un dominio a otro.

Por ejemplo, dada una cara feliz, queremos transformarla en una cara de miedo.

# Aplicaciones

## StarGAN

<https://arxiv.org/pdf/1711.09020.pdf>

StarGAN es una traducción de imagen a imagen de un dominio a otro.

Por ejemplo, dada una cara feliz, queremos transformarla en una cara de miedo.




# Aplicaciones

## StarGAN

<https://arxiv.org/pdf/1711.09020.pdf>

En (b), el generador genera una imagen falsa basada en una imagen de entrada y una etiqueta de dominio de destino (por ejemplo, enojado).

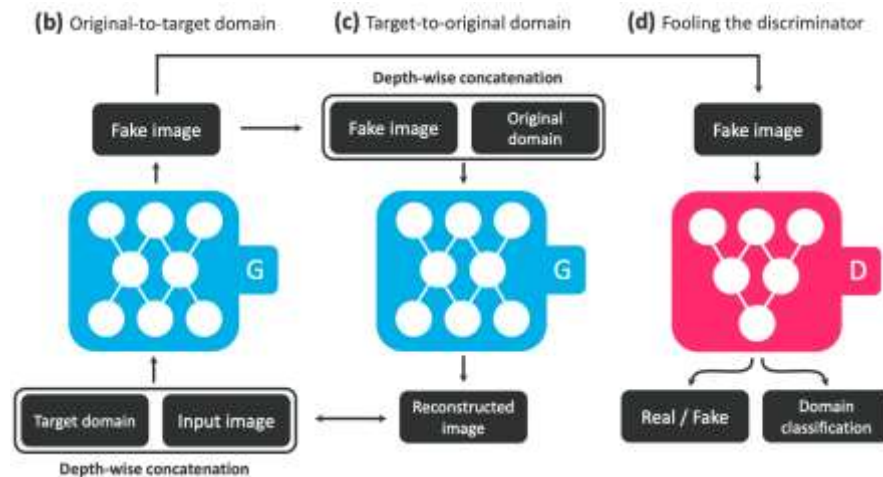


# Aplicaciones

## StarGAN

<https://arxiv.org/pdf/1711.09020.pdf>

En (d), alimentamos imágenes reales y falsas al discriminador para etiquetarlo como real o no, así como su clasificación de dominio.




# Aplicaciones

## StarGAN

<https://arxiv.org/pdf/1711.09020.pdf>

La función de costo involucrará errores de reconstrucción así como el costo del discriminador en la identificación de las imágenes y sus etiquetas.



# Aplicaciones

PixelDTGAN

<https://github.com/fxia22/PixelDTGAN>



# Aplicaciones

PixelDTGAN

<https://github.com/fxia22/PixelDTGAN>



A source image.



Possible target images.

# Aplicaciones

PixelDTGAN

<https://github.com/fxia22/PixelDTGAN>

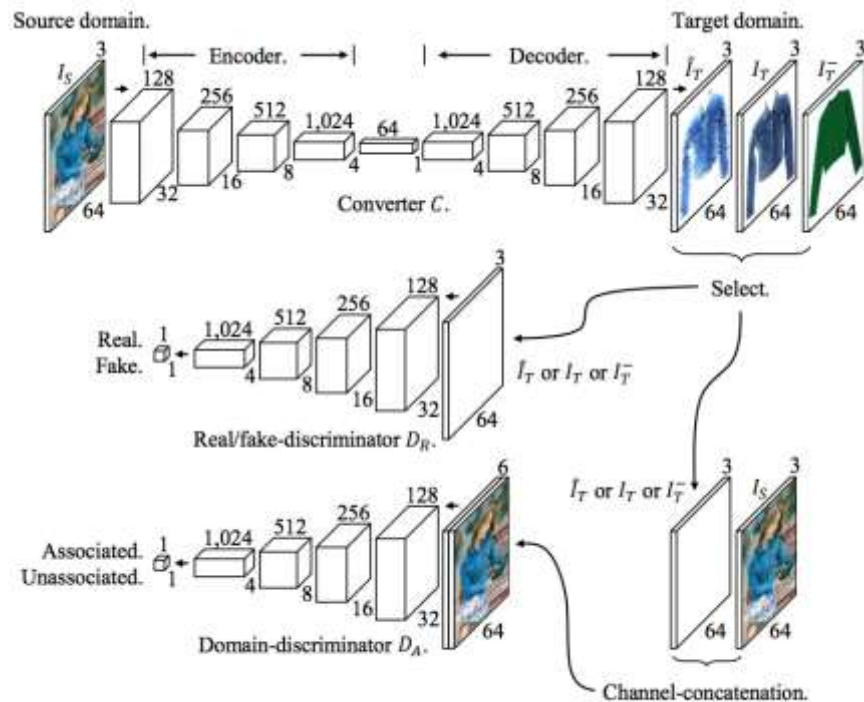
Example results on LOOKBOOK dataset (top), left is input, right is generated clothes. Results on a similar dataset (bottom). More results will be added soon.



# Aplicaciones

PixelDTGAN

<https://github.com/fxia22/PixelDTGAN>



**Fig. 2.** Whole architecture for pixel-level domain transfer.

# Aplicaciones

## SuperResolution GAN

<https://arxiv.org/pdf/1609.04802.pdf>



Figure 2: From left to right: bicubic interpolation, deep residual network optimized for MSE, deep residual generative adversarial network optimized for a loss more sensitive to human perception, original HR image. Corresponding PSNR and SSIM are shown in brackets. [4× upscaling]

# Aplicaciones

StyleGAN 2

<https://arxiv.org/pdf/1912.04958.pdf>



# Aplicaciones

Text 2 Imagen GAN (StackGAN)

<https://github.com/hanzhanggit/StackGAN>

This flower has long thin yellow petals and a lot of yellow anthers in the center

Stage-I



Stage-II





# Aplicaciones

Text 2 Imagen GAN (StackGAN)

<https://github.com/hanzhanggit/StackGAN>

A white bird with a black crown and yellow beak

Stage-I



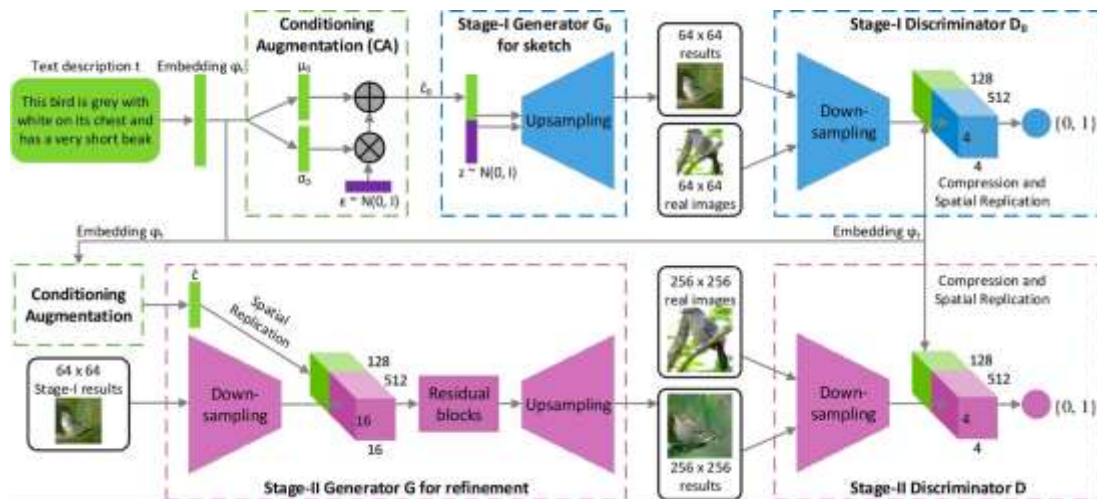
Stage-II



# Aplicaciones

## Text 2 Imagen GAN (StackGAN)

<https://github.com/hanzhanggit/StackGAN>

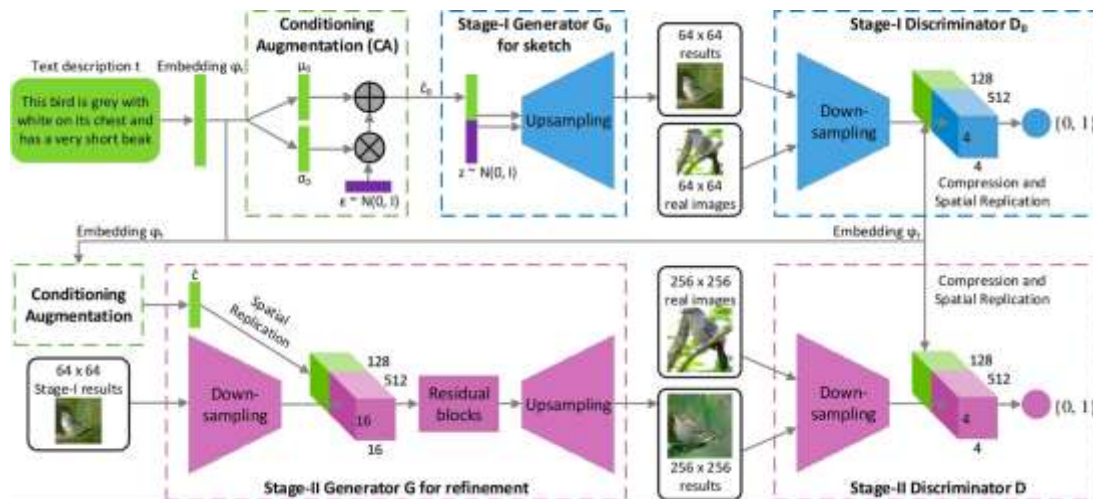




# Aplicaciones

## Text 2 Imagen GAN (StackGAN)

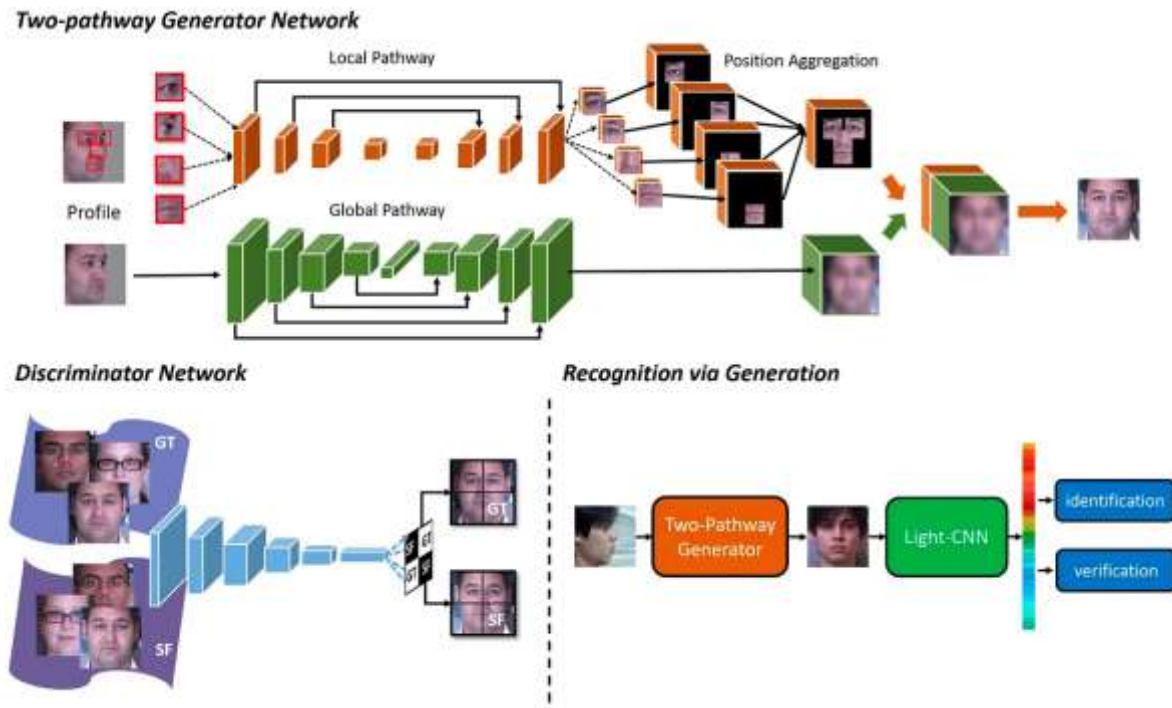
<https://github.com/hanzhanggit/StackGAN> - Demo: <https://www.craiyon.com/>



# Aplicaciones

TPGAN

<https://arxiv.org/pdf/1704.04086.pdf>

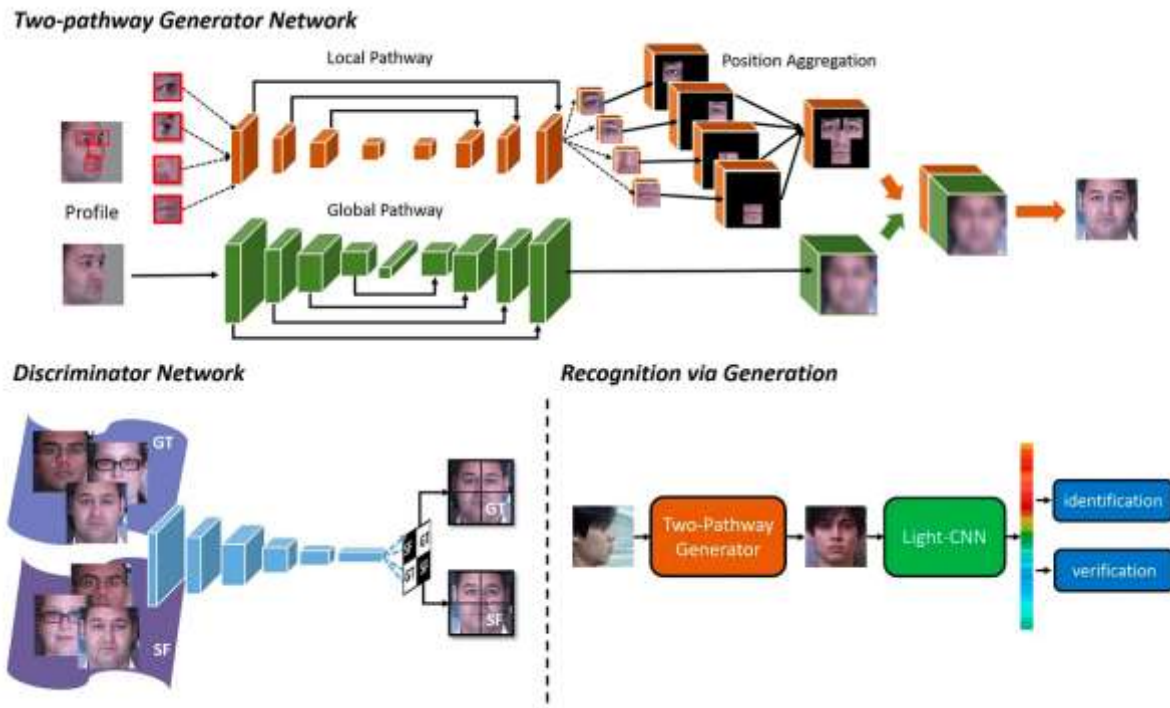


# Aplicaciones

## TPGAN

<https://arxiv.org/pdf/1704.04086.pdf>

Caras de síntesis en diferentes poses: Con una única imagen de entrada, crea caras en diferentes ángulos de visión.

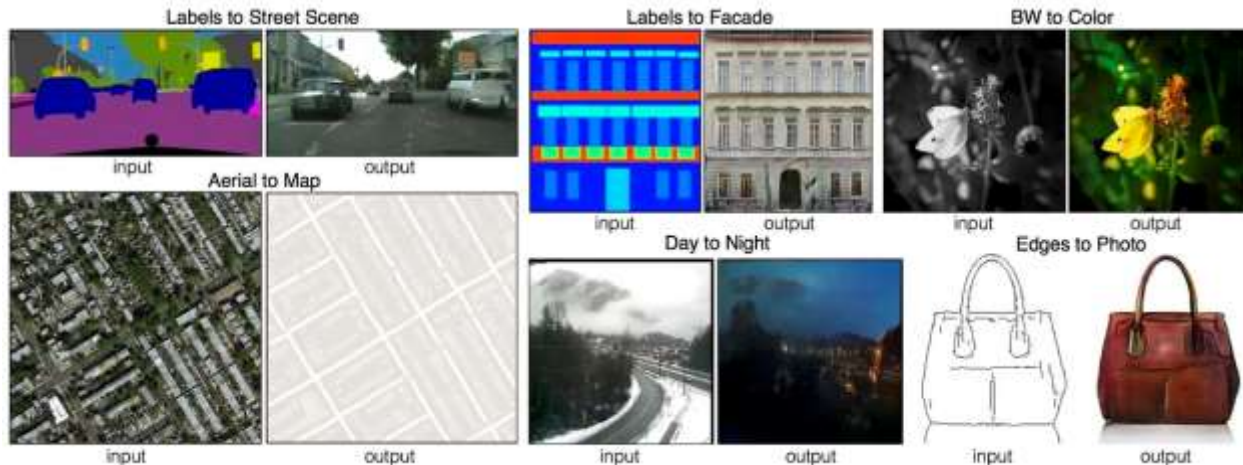


# Aplicaciones

Pix2Pix

<https://github.com/phillipi/pix2pix>

Traducción de imágenes  
en diferentes tareas.



# Aplicaciones

DeBlur

<https://arxiv.org/pdf/1711.07064.pdf>



Figure 2: GoPro images [25] processed by DeblurGAN. Blurred – left, DeblurGAN – center, ground truth sharp – right.

# Aplicaciones

Neural Photo Editor

[https://github.com/ajbrock/  
Neural-Photo-Editor](https://github.com/ajbrock/Neural-Photo-Editor)

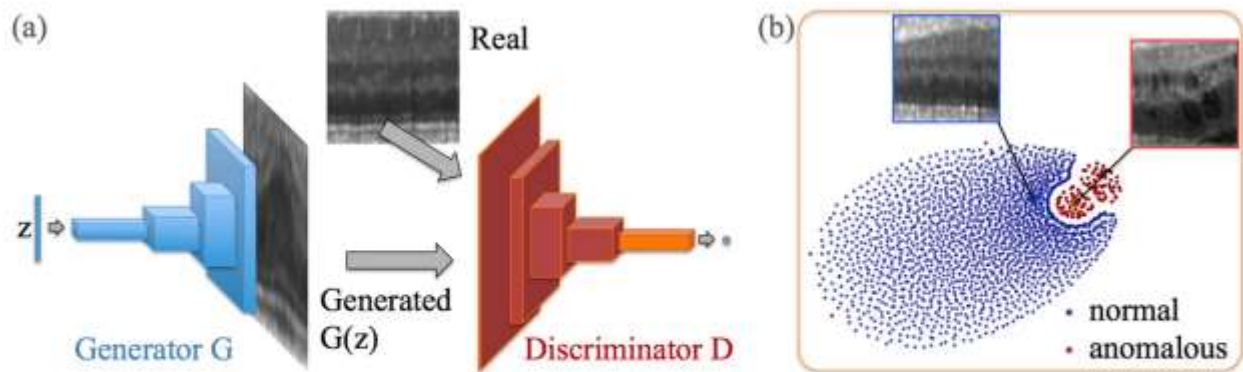





# Aplicaciones

MediGAN

<https://arxiv.org/pdf/1703.05921.pdf>



**Fig. 2.** (a) Deep convolutional generative adversarial network. (b) t-SNE embedding of normal (blue) and anomalous (red) images on the feature representation of the last convolution layer (orange in (a)) of the discriminator.

# Aplicaciones

## 3D GAN

[https://proceedings.neurips.cc/paper\\_files/paper/2016/file/44f683a84163b3523afe57c2e008bc8c-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2016/file/44f683a84163b3523afe57c2e008bc8c-Paper.pdf)





# Aplicaciones

## 3D GAN

[https://proceedings.neurips.cc/paper\\_files/paper/2016/file/44f683a84163b3523afe57c2e008bc8c-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2016/file/44f683a84163b3523afe57c2e008bc8c-Paper.pdf)




Figure 1: The generator in 3D-GAN. The discriminator mostly mirrors the generator.

# Fuentes:

GAN (2014) Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, Yoshua Bengio

<https://arxiv.org/abs/1406.2661>

<https://github.com/soumith/ganhacks>

<https://jonathan-hui.medium.com/gan-some-cool-applications-of-gans-4c9ecca35900>